



Índice

1. Regresión Logística	2
1.1. Importar las librerías	2
1.2. Importar del Dataset	2
1.3. Estadísticas básicas	3
1.4. Visualización de Distribuciones	3
1.5. Exploración Inicial de los datos	4
1.6. Codificar las variables categoricas	4
1.7. Dividir el dataset en conjunto de Training y conjunto de Test	5
1.8. Escalado de características	6
1.9. Entrenar el modelo de Regresión Logística con el conjunto de Training	6
1.10. Predecir los resultados de conjunto de Test	6
1.11. Predecir las probabilidades para el conjunto de Test y Training	7
1.12. Matriz de confusión y Metrics	7



1 Regresión Logística

1.1 Importar las librerías

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import pandas as pd
4 import statsmodels.api as sm
5 import seaborn as sns
6 from sklearn.preprocessing import StandardScaler
7 from sklearn.model_selection import train_test_split
```

1.2 Importar del Dataset

```
1 dataset =
  ↳ pd.read_csv('https://raw.githubusercontent.com/dxnxsxn/...customers.csv')
2 X = dataset.iloc[:, :-1].values
3 y = dataset.iloc[:, -1].values
4 dataset.head()
5 X[:1]
6 y[:1]
```

	CustomerID	Age	Gender	AnnualIncome	MaritalStatus	PurchasedInsurance
0	1	44	Male	39481	Single	0
1	2	48	Male	140583	Married	0
2	3	23	Female	70068	Married	0
3	4	33	Female	94433	Married	0
4	5	55	Male	115016	Married	1


1.3 Estadísticas básicas


```
1 dataset.describe()
```

	CustomerID	Age	AnnualIncome	PurchasedInsurance
count	100.000000	100.0000	100.000000	100.000000
mean	50.500000	42.3100	90994.310000	0.540000
std	29.011492	14.1512	36169.377881	0.500908
min	1.000000	18.0000	31291.000000	0.000000
25%	25.750000	30.7500	60090.000000	0.000000
50%	50.500000	42.5000	92199.000000	1.000000
75%	75.250000	54.0000	124363.500000	1.000000
max	100.000000	68.0000	148146.000000	1.000000

1.4 Visualización de Distribuciones


```
1 #Visualización de las distribuciones
2 plt.figure(figsize=(16, 10))
3 for i, column in enumerate(['CustomerID', 'Age', 'AnnualIncome',
4     ↪ 'PurchasedInsurance']):
5     plt.subplot(2, 2, i+1)
6     sns.histplot(dataset[column], kde=True, bins=30)
7     plt.title(f'Distribución de {column}')
8     plt.xlabel(column)
9     plt.ylabel('Frecuencia')
10 plt.tight_layout()
11 plt.show()
```





1.5 Exploración Inicial de los datos

```
1 # Ver que valores hay en la columna a predecir
2 unique, counts = np.unique(y, return_counts=True)
3 plt.pie(counts, labels=unique, autopct='%0f%%')
```



1.6 Codificar las variables categoricas

```
1 # Para la columna Gender
2 from sklearn.compose import ColumnTransformer
3 from sklearn.preprocessing import OneHotEncoder
4 ct = ColumnTransformer(transformers=[('encoder', OneHotEncoder(), [1])],
5     ↳ remainder='passthrough')
6 X = np.array(ct.fit_transform(X))
7 X[:1]
8
```



```
9 X=X[:, 1:] # Eliminamos la primera fila para evitar la colinealidad, se puede
    ↪ eliminar cualquier fila para evitarlo.
10 X[:1]
11
12 # Para la columna MaritalStatus
13 from sklearn.compose import ColumnTransformer
14 from sklearn.preprocessing import OneHotEncoder
15 ct = ColumnTransformer(transformers=[('encoder', OneHotEncoder(), [3])],
    ↪ remainder='passthrough')
16 X = np.array(ct.fit_transform(X))
17
18 X[:1]
19
20 X=X[:, 1:] # Eliminamos la primera fila para evitar la colinealidad, se puede
    ↪ eliminar cualquier fila para evitarlo.
21 X[:1]
22
23 # Para la columna MaritalStatus
24 from sklearn.compose import ColumnTransformer
25 from sklearn.preprocessing import OneHotEncoder
26 ct = ColumnTransformer(transformers=[('encoder', OneHotEncoder(), [3])],
    ↪ remainder='passthrough')
27 X = np.array(ct.fit_transform(X))
28
29 X[:1]
30
31 X=X[:, 1:] # Eliminamos la primera fila para evitar la colinealidad, se puede
    ↪ eliminar cualquier fila para evitarlo.
32 X[:1]
```

1.7 Dividir el dataset en conjunto de Training y conjunto de Test

```
1 from sklearn.model_selection import train_test_split
2 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.25,
    ↪ random_state = 0)
3
4 # Ver que valores hay en la columna a predecir
5 unique, counts = np.unique(y_test, return_counts=True)
6 plt.pie(counts, labels=unique, autopct='%.3f%%')
7
8 X_test[:1]
9
10 y_test[:1]
```

1.8 Escalado de características


```
1 # Paso 1: Extraer columnas 2 y 3 y convertirlas a float
2 cols_to_scale = X[:, [2, 3]].astype(np.float64) # ¡Conversión explícita
   ↪ necesaria!
3
4 # Paso 2: Estandarizar
5 scaler = StandardScaler()
6 scaled_cols = scaler.fit_transform(cols_to_scale)
7
8 # Paso 3: Reemplazar en el array original
9 X[:, [2, 3]] = scaled_cols
10 X[:, 1]
```

1.9 Entrenar el modelo de Regresión Logística con el conjunto de Training

```
1 from sklearn.linear_model import LogisticRegression
2 classifier = LogisticRegression(random_state = 23)
3 classifier.fit(X_train, y_train)
```

1.10 Predecir los resultados de conjunto de Test

```
1 y_pred = classifier.predict(X_test)
```



1.11 Predecir las probabilidades para el conjunto de Test y Training

```
1 y_prob_train = classifier.predict_proba(X_train)[: ,1]
2 y_probs = classifier.predict_proba(X_test)[: , 1]
3 # y_probs_test[:3]
```

1.12 Matriz de confusión y Metricas

```
1 from sklearn.metrics import roc_auc_score, accuracy_score, precision_score,
  ↪ recall_score, f1_score, confusion_matrix
2 cm = confusion_matrix(y_test, y_pred)
3 print(cm) # Matriz de Confusión
4
5 # Calculate the AUC - ROC score
6 roc_auc = roc_auc_score(y_test, y_probs)
7
8 # Calculate other metrics
9 accuracy = accuracy_score(y_test, y_pred)
10 precision = precision_score(y_test, y_pred, zero_division=0)
11 recall = recall_score(y_test, y_pred)
12 f1 = f1_score(y_test, y_pred)
13
14 # Print the metrics
15 print(f"AUC - ROC Score: {roc_auc:.3f}")
16 print(f"Accuracy: {accuracy:.3f}")
17 print(f"Precision: {precision:.3f}")
18 print(f"Recall: {recall:.3f}")
19 print(f"F1 Score: {f1:.3f}")
```
